

STUDIO DELLE TECNICHE DI CLASSIFICAZIONE DI GENERI MUSICALI – A.A. 2023/2024

Mattero Romeo e Davide Orienti

535005 - 533107

Indice Generale

1	Introduzione	1
2	Capitolo 1: Studio del Dataset	2
3	Capitolo 2: Studio delle Features	2
3.1	Capitolo 2.1: Selezione delle features	4
3.1.1	CAPITOLO 2.1.1: Correlazione tra features	4

1 Introduzione

Questo studio si basa sullo studio dell'abilità di un sistema di Machine Learning di identificare e classificare il genere musicale di una traccia audio. Il dataset utilizzato per questo task è noto dataset GTZAN (<https://www.kaggle.com/datasets/andradaolteanu/gtzan-dataset-music-genre-classification>), un dataset formato da dieci generi musicali distinti, ciascuno composto da 100 tracce audio. I generi musicali che si trovano all'interno di questo dataset sono: blues, classical, country, hiphop, disco, jazz, metal, rock, pop e reggae. Ogni traccia audio è della durata di circa 30 secondi e rappresenta una composizione tipica del genere a cui appartiene, rendendo il dataset ideale per le applicazioni di classificazione. Nel presente studio, verrà analizzata e confrontata l'efficacia di diverse tecniche di estrazione delle feature e di modelli di classificazione, confrontando i risultati ottenuti in termini di accuratezza e robustezza. Come prima analisi si è andato a studiare la distribuzione e caratteristiche dei dati all'interno del dataset. Dopodichè sono state provate e valutate alcune tecniche di feature engineering come creazione di nuove features, selezione di features e trasformazioni di features. Dopo aver effettuato queste tecniche sono stati provate alcune delle tecniche studiate durante il corso e confrontati i risultati ottenuti. Infine è stata sviluppata una rete neurale per tentare di migliorare i dati ottenuti con l'utilizzo di tecniche di machine learning

2 Capitolo 1: Studio del Dataset

Il dataset scelto per questo progetto, noto come GTZAN(<https://www.kaggle.com/datasets/andradaolteanu/gtzan-dataset-music-genre-classification>) , rappresenta una delle risorse più rilevanti e consolidate nell'ambito della classificazione musicale, fornendo un'ampia gamma di dati utili per l'analisi dei generi musicali. Questo dataset è strutturato in dieci generi musicali: blues, classical, country, hiphop, disco, jazz, metal, rock, pop e reggae. Ogni genere contiene esattamente 100 file audio della durata di 30 secondi ciascuno, garantendo una struttura bilanciata e uniforme che facilita il processo di analisi e interpretazione. L'uniformità del dataset riduce il rischio di sbilanciamenti tra le classi, un aspetto che potrebbe influire negativamente sui risultati di classificazione. Oltre ai file audio, GTZAN contiene ulteriori cartelle con gli spettrogrammi estratti e un insieme di features derivate dai file audio originali. Queste componenti aggiuntive permettono di approcciare il dataset da diverse prospettive analitiche. Per la prima fase del progetto, l'attenzione si è focalizzata sulle features estratte, utilizzando queste come base per costruire modelli di classificazione. La fase successiva ha incluso l'utilizzo degli spettrogrammi e dei file audio originali per sviluppare e addestrare una rete neurale, con l'obiettivo di migliorare le capacità di classificazione e valutare le prestazioni del modello su diverse rappresentazioni dei dati. Un'ulteriore analisi della composizione del dataset ha evidenziato una distribuzione uniforme tra i generi: ciascun genere è rappresentato esattamente da 100 campioni della stessa durata, aspetto che assicura l'assenza di un sovra- o sottorappresentazione di un particolare genere. Oltre ai dati di 30 secondi, GTZAN include anche una rappresentazione dei campioni in formato ridotto. In questo file, ogni traccia è stata suddivisa in dieci segmenti di 3 secondi ciascuno, portando il numero totale dei campioni a 10.000 e incrementando la granularità del dataset. Tale suddivisione permette di aumentare il numero complessivo dei dati forniti al modello, aspetto che può influire positivamente sulle prestazioni complessive della classificazione. Poiché il dataset è etichettato in modo completo, si è scelto un approccio di apprendimento supervisionato, evitando di ricorrere a tecniche di apprendimento non supervisionato. Questo approccio permette di sfruttare al massimo le informazioni presenti nelle etichette, supportando il modello nella distinzione tra i generi musicali.

3 Capitolo 2: Studio delle Features

Il dataset GTZAN include un insieme di 60 **features** estratte dai file audio, ciascuna delle quali fornisce una rappresentazione specifica delle caratteristiche acustiche dei brani. Queste *features* sono state scelte per facilitare il modello di apprendimento nella distinzione tra i vari generi musicali. Di seguito una panoramica delle *features* contenute nel dataset:

- **filename**: Nome del file audio, utilizzato principalmente per identificare il campione e non rilevante per la classificazione.
- **length**: Durata del file audio in secondi.
- **chroma_stft_mean** e **chroma_stft_var**: Media e varianza della trasformata di Fourier con componenti cromatiche, utili per l'analisi delle tonalità e degli accordi.
- **rms_mean** e **rms_var**: Media e varianza del Root Mean Square (RMS) dell'ampiezza, indicano l'intensità sonora media.

- **spectral_centroid_mean** e **spectral_centroid_var**: Media e varianza del centroide spettrale; un valore elevato indica una predominanza di frequenze alte.
- **spectral_bandwidth_mean** e **spectral_bandwidth_var**: Media e varianza della larghezza di banda spettrale, che indica l'ampiezza della gamma di frequenze attorno al centroide spettrale.
- **rolloff_mean** e **rolloff_var**: Media e varianza della frequenza di roll-off, ossia il punto in cui si accumula l'85% dell'energia spettrale.
- **zero_crossing_rate_mean** e **zero_crossing_rate_var**: Media e varianza della frequenza di attraversamento dello zero, utili per distinguere tra suoni rumorosi e tonalità più morbide.
- **harmony_mean** e **harmony_var**: Media e varianza dell'armonia, descrivono la componente armonica del suono e sono cruciali per l'identificazione delle tonalità.
- **perceptr_mean** e **perceptr_var**: Media e varianza del contrasto percepibile, utilizzato per distinguere le strutture armoniche dal rumore.
- **tempo**: Velocità del brano espressa in battiti per minuto (BPM), utile nella classificazione di generi ritmici.
- **mfcc1_mean - mfcc20_mean** e **mfcc1_var - mfcc20_var**: Media e varianza dei primi 20 coefficienti Mel-Frequency Cepstral Coefficients (MFCC), che rappresentano la forma spettrale del segnale audio su una scala non lineare che riflette la percezione umana delle frequenze. I MFCC sintetizzano informazioni cruciali sull'intonazione e sul timbro del brano e sono fondamentali per la classificazione.
- **label**: Etichetta che identifica il genere musicale del file audio, utilizzata come variabile target per il modello.

Queste *features* forniscono una rappresentazione completa dei file audio, coprendo sia aspetti spettrali (come le frequenze e l'intensità) sia aspetti temporali (come il ritmo e l'armonia). Grazie a queste caratteristiche, è possibile distinguere i generi musicali poiché ciascun genere tende a presentare schemi distinti in termini di frequenze dominanti, intensità, ritmo e armoniche.

L'uniformità dei campioni di 30 secondi con 100 file per ogni genere garantisce che non vi sia predominanza di alcuna classe. La presenza dei campioni suddivisi in segmenti da 3 secondi, per un totale di 10.000 file, migliora ulteriormente la granularità del dataset. Questo aumento di granularità, inoltre, consente al modello di analizzare le variazioni temporali interne di ciascun file, supportando un'analisi più dettagliata del contenuto sonoro.

Infine, dopo aver analizzato e compreso la struttura delle *features*, abbiamo intrapreso l'applicazione di tecniche di *feature engineering* per ottimizzare ulteriormente le performance del modello e migliorare i risultati di classificazione.

3.1 Capitolo 2.1: Selezione delle features

3.1.1 CAPITOLO 2.1.1: Correlazione tra features

Come prima operazione, ci siamo concentrati sull'analisi delle correlazioni tra le varie features del dataset per identificare eventuali coppie di features con correlazioni elevate. Siamo quindi andati a creare la matrice di correlazione. Studiando i valori della matrice sappiamo che valori prossimi a 1 o a -1 indicano una forte correlazione tra due features, segnalando una relazione lineare diretta o inversa. Quando due features risultano esattamente correlate (valore di correlazione pari a 1 o -1), è possibile eliminare una delle due senza perdita di informazione significativa, semplificando così il modello e riducendo la dimensionalità.

Immagini/image.png

Figure 1: Distribuzione delle 22 query con evidenza per quelle *CPU-intensive* e *Disk-intensive*.

Step 2